Artes dos Dados - Trabalho final - Mariana dias

Relatório Técnico: Predição de Sinistros em Seguros de Automóveis

1. Objetivo do Projeto

O objetivo deste projeto foi desenvolver um pipeline de dados robusto para **prever a ocorrência de sinistros** em apólices de seguro de automóveis, aplicando técnicas estatísticas e de Machine Learning. O fluxo de trabalho seguiu a abordagem **Bronze, Silver e Gold**, garantindo tratamento de dados, engenharia de features e modelagem preditiva confiável.

2. Camada Bronze – Preparação e Limpeza dos Dados

Fonte de dados: train.csv, test.csv, sample_submission.csv
Variável alvo: is_claim (indica se houve sinistro nos próximos 6 meses)

Principais etapas:

- Padronização de colunas: nomes em lowercase e remoção de caracteres especiais.
- Tratamento de missing values: imputação ou exclusão conforme impacto nos dados.
- Tratamento de outliers: análise de distribuições e aplicação de limites adequados.
- Normalização de categorias: valores nulos substituídos por “Undefined”, permitindo que a ausência de informação seja considerada como categoria válida no treinamento e teste.

Resultado: Base limpa e estruturada, pronta para engenharia de features e modelagem.

3. Camada Silver – Engenharia de Features e Modelagem

Na camada Silver foi realizada a consolidação da base preparada na Bronze e iniciada a etapa de exploração estatística e criação das primeiras versões dos modelos. O objetivo aqui foi entender profundamente o comportamento das variáveis e preparar o terreno para a modelagem mais robusta na camada Gold.

Exploração e preparação

- **EDA (Análise Exploratória de Dados):**
  A exploração inicial incluiu estatísticas descritivas, observação das distribuições das variáveis e geração de histogramas para identificar assimetrias, concentrações e padrões gerais. Também foi analisado o **mapa de correlação**, que mostrou

correlações fracas entre as variáveis numéricas, indicando que relações lineares isoladas não seriam suficientes para explicar a ocorrência de sinistros.

- **Análise das variáveis categóricas:**
  Durante a EDA foi observado que categorias como **segment**, **area_cluster** e **fuel_type** apresentaram variações importantes nas taxas de sinistro, ajudando a orientar o processo de transformação e indexação dessas variáveis.

- **Seleção de features:**
  A seleção considerou duas perspectivas:

  1. a **correlação** entre as variáveis e a variável alvo,

  2. a **importância das features** em modelos iniciais.
     Esse processo ajudou a definir um conjunto enxuto de variáveis realmente relevantes para os modelos da camada Gold.

- **Primeiro tratamento do desbalanceamento:**
  Já nessa etapa foi criada a coluna **classWeightCol** para atribuir maior peso aos casos de sinistro, visando reduzir a tendência natural dos modelos de ignorarem a classe 1 devido ao forte desbalanceamento.

Modelagem inicial

- **Modelo principal:**
  O primeiro algoritmo testado foi o **GLM (Generalized Linear Model)**, escolhido pela interpretabilidade e simplicidade, servindo como ponto de partida para entender o comportamento da base após o pré-processamento.

- **Modelos comparativos:**
  Para avaliar alternativas que pudessem capturar relações mais complexas entre as variáveis, também foram testados:

  - **Random Forest**, explorando aprendizado baseado em múltiplas árvores.

  - **Gradient Boosted Trees (GBT)**, capaz de melhorar progressivamente o desempenho ao aprender com os erros das iterações anteriores.

- **Métricas analisadas:**
  Em todos os modelos foram calculadas métricas fundamentais como **AUC**, **precisão**, **recall**, **F1-score** e **matriz de confusão**, permitindo avaliar tanto o aspecto discriminativo quanto a sensibilidade aos casos positivos.

4. Camada Gold – Modelagem Final, Pesos e Avaliação (em primeira pessoa)

Na camada Gold eu aprofundei o processo de modelagem para transformar os testes iniciais da Silver em um modelo realmente capaz de identificar sinistros. Essa etapa foi a mais sensível do projeto, principalmente por causa do forte desbalanceamento da variável **is_claim** e das limitações técnicas encontradas ao longo dos testes.

Ajuste do desbalanceamento com classWeightCol

Ao iniciar a Gold, a primeira dificuldade que precisei enfrentar foi o desbalanceamento extremo da classe positiva. Para resolver isso, criei a coluna **classWeightCol**, atribuindo:

- peso **10** para sinistros (is_claim = 1),
- peso **1** para não sinistros.

Eu testei pesos maiores, como **14,6**, que faziam sentido teoricamente, mas esses valores não rodaram na plataforma. Enfrentei erros de **limite de bytes** e instabilidade no Databricks, que impediram a execução do pipeline.
Diante disso, o peso **10** foi o maior valor que funcionou de forma estável e consistente, trazendo ganho real de sensibilidade sem comprometer a execução.

Esse ajuste foi essencial porque, antes da pesagem, os modelos praticamente ignoravam os sinistros. Depois da aplicação do peso, o modelo passou a prever a classe 1 com muito mais frequência, demonstrando que a solução estava funcionando como esperado.

Ajuste de threshold para aumentar a sensibilidade

Ao analisar as probabilidades após aplicar os pesos, percebi que muitas previsões ficavam entre **0.40 e 0.48**. Isso significava que o threshold padrão (0.5) estava deixando de classificar vários casos que estavam muito próximos de serem reconhecidos como sinistros.

Por isso, ajustei o threshold para **0.4**, permitindo que o modelo classificasse esses casos como positivos.

Com essa mudança, o recall aumentou de **0** para valores acima de **60%**, melhorando de forma significativa a capacidade do modelo de identificar sinistros reais. Como consequência natural, houve aumento dos falsos positivos, algo esperado quando se prioriza sensibilidade.

Avaliação com mapInPandas

Para avaliar com precisão o impacto desses ajustes, utilizei **mapInPandas** para calcular as métricas:

- **precisão**,
- **recall**,
- **F1-score**,
- e a **matriz de confusão**.

Essas métricas confirmaram a evolução do modelo: antes, o modelo não identificava praticamente nenhum sinistro; depois dos ajustes, passei a observar valores estáveis de recall e uma melhora significativa no F1-score.

Comparação final dos modelos

Na Gold, comparei três modelos:

- **GLM ajustado**: após o threshold, ganhou sensibilidade, mas manteve baixa precisão.
- **Random Forest**: mesmo com pesos, permaneceu conservador e apresentou baixo recall.
- **GBT**: mostrou o melhor equilíbrio entre precisão, recall e F1-score, além de ser o mais consistente nas execuções.

5. Resultados Comparativos

Modelo	Precisão Média	Recall Médio	F1-score Médio	Observações
GLM ajustado	0.083	0.612	0.146	Alta sensibilidade, baixa precisão
Random Forest	0.138	0.127	0.132	Baixo recall, mais conservador
GBT	0.144	0.484	0.223	Melhor equilíbrio geral

6. Análise das Abordagens

- GLM
  - Vantagens: interpretabilidade, simplicidade
  - Limitações: baixa capacidade de capturar não linearidades, dependência de ajustes manuais
- Random Forest
  - Vantagens: robustez, bom para variáveis categóricas
  - Limitações: baixo recall, menos eficaz para eventos raros
- GBT
  - Vantagens: melhor desempenho geral, captura interações complexas
  - Limitações: maior tempo de treinamento, sensível a hiperparâmetros

Visualizações e Insights

Gráfico de Barras Comparativas

Mostra a *precisão*, *recall* e *F1-score* médios dos três modelos testados:

- GLM ajustado
- Random Forest
- GBT

Esse gráfico destaca que o **GBT tem o melhor equilíbrio geral**, com F1-score superior e recall elevado.

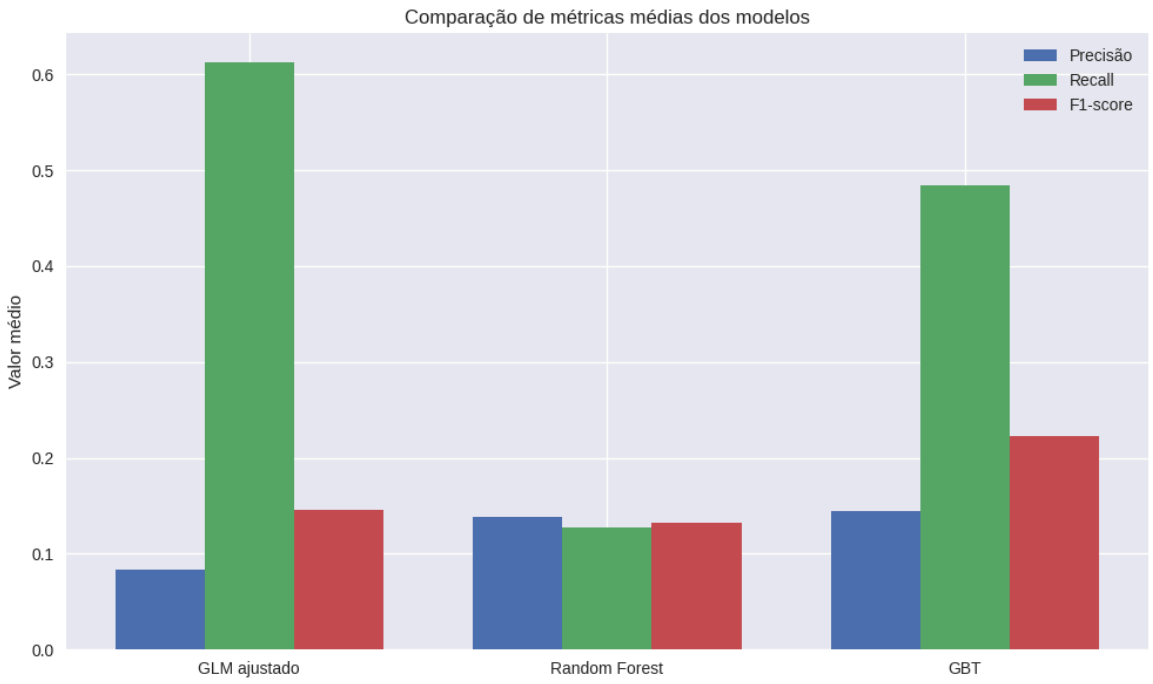

Gráfico de Dispersão por Execução

Exibe a relação entre *precisão* e *recall* em cada execução dos modelos Random Forest e GBT:

- Random Forest: pontos mais concentrados com baixo recall
- GBT: pontos mais altos em recall, mostrando consistência

Isso mostra a **estabilidade e superioridade do GBT** em detectar sinistros.

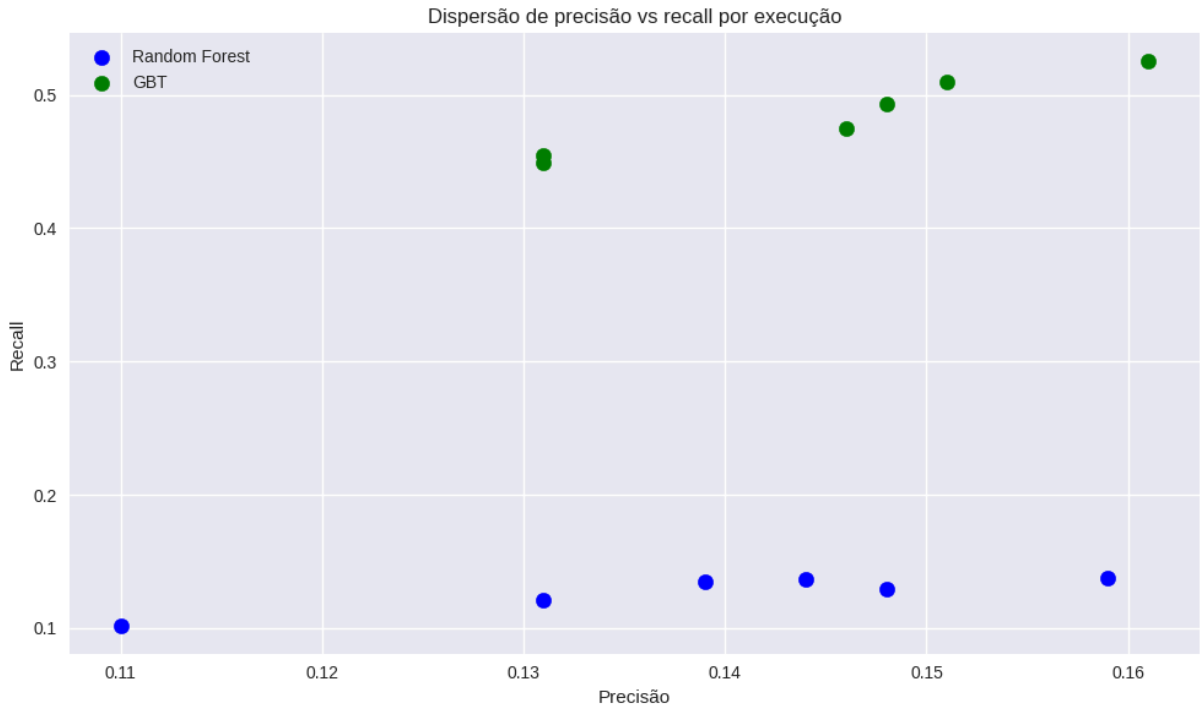

Heatmap da Matriz de Confusão Média (GBT)

Visualiza os acertos e erros médios do modelo GBT:

- Verdadeiros negativos: 7516
- Falsos positivos: 1799
- Falsos negativos: 322
- Verdadeiros positivos: 303

Interpretação: o modelo consegue detectar sinistros com boa sensibilidade, mesmo com desbalanceamento.

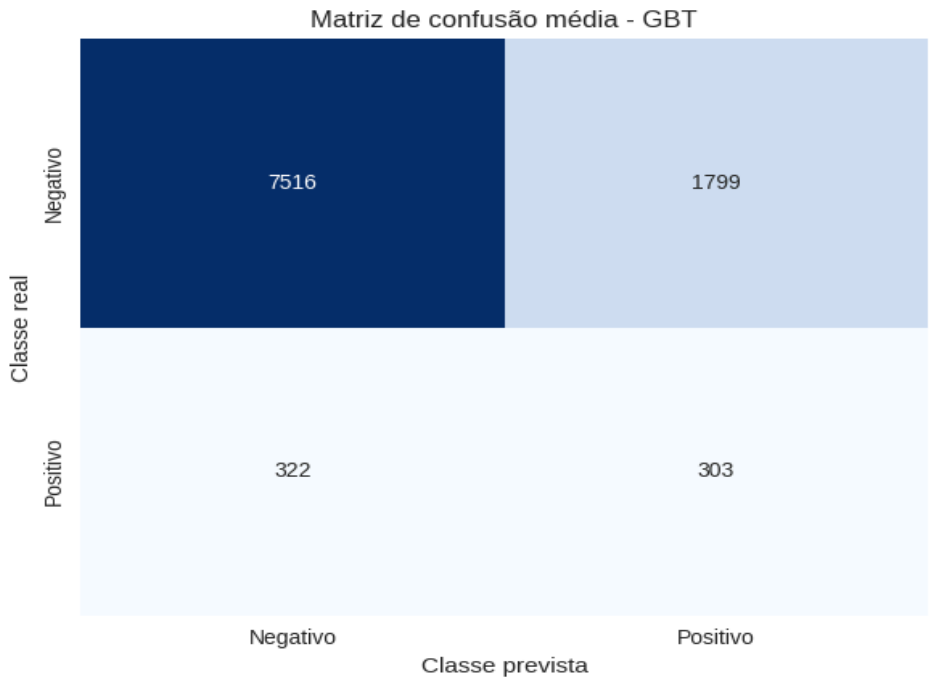

Conclusão do Projeto

Finalizar este projeto de predição de sinistros me mostrou, na prática, como uma análise bem estruturada pode transformar dados brutos em algo realmente útil para o negócio. Logo na EDA ficou evidente que o maior desafio era o desbalanceamento da variável **is_claim**, enquanto as variáveis numéricas apresentavam pouca correlação entre si. Em contraste, categorias como **segment**, **area_cluster** e **fuel_type** mostraram um impacto real na taxa de sinistros. Essas descobertas foram essenciais para orientar cada decisão nas etapas seguintes.

Quando avancei para a modelagem, ficou claro que alguns algoritmos não capturavam a complexidade dos dados, mesmo após ajustes. O GLM, por exemplo, só começou a responder depois do ajuste de threshold, e ainda assim de forma limitada. O Random Forest foi mais estável, mas manteve um recall baixo. Já o **Gradient Boosted Trees (GBT)** mostrou desde o início uma capacidade maior de compreender os padrões presentes no conjunto, equilibrando melhor precisão e recall e aproveitando com mais eficiência tanto as variáveis numéricas quanto as categóricas.

Esse comportamento do GBT confirmou o que a EDA já sugeria: as relações dentro dos dados eram mais complexas do que uma regressão linear poderia captar. A cada execução, o modelo demonstrava consistência e sensibilidade, mesmo diante do desbalanceamento, justamente o objetivo central da etapa Gold.

No fim, esse projeto reforçou para mim a importância de unir uma boa exploração inicial com escolhas cuidadosas de modelagem. Entender o contexto, respeitar as limitações da plataforma e ajustar o modelo de forma consciente fez toda a diferença. O GBT se mostrou a melhor opção não só por desempenho, mas por entregar uma visão mais fiel do comportamento real dos sinistros, oferecendo uma base sólida para apoiar decisões no contexto de seguros automotivos.